머신러닝 기초 2·3일차 복습 노트

Nov 6, 2026 · @duru

한눈에 보는 2·3일차

2일차는 **분류와 군집** — "누가 떠날까, 누구끼리 비슷할까". 3일차는 **딥러닝** — "사진과 리뷰 글을 어떻게 분류할까". 사흘 모두 같은 순서를 밟았다: 문제를 정하고, 데이터를 보고, 모델을 고르고, 목적에 맞는 지표로 결과를 읽었다.

순서	수업	핵심 질문	한 줄 결론
6	분류로 어느 쪽인지 맞히기	정확도 81%를 그대로 보고해도 될까?	혼동행렬 네 칸으로 나눠 재현율(놓치지 않았나)과 정밀도(찾은 게 진짜나)를 같이 본다. 어느 실수가 비싼지가 지표를 정한다
7	Orange3로 모델 비교	모델만 바꾸면 얼마나 달라질까?	데이터에 따라 격차가 다르다(22.8%p vs 3%p). 훈련 점수와 교차검증 점수의 차이가 과적합
8	조용히 떠나는 고객 미리 찾기	누구부터 전화할까?	임계값·가중치만 바꿔도 재현율이 20%p 오른다. 보고는 "874명 중 447명"처럼 운영의 말로
9	군집으로 고객 묶기	정답 열이 없으면 무엇을 할 수 있나?	k-means로 묶고, 그룹 이름과 할 일은 사람이 붙인다. 분류는 '누구에게', 군집은 '무슨 말을'
10	딥러닝 첫걸음	열이 없는 데이터는 어떻게?	사진·문장은 사람이 특성을 고를 수 없다. 다층 신경망이 특성을 스스로 만든다. 층을 너무 쌓으면 과적합
11	사전 학습 모델	가중치 354만 개를 어떻게 찾나?	남이 찾아 둔 가중치를 Hugging Face에서 빌려 쓴다. 무엇으로 학습했는지부터 확인
12	중고거래 상품 사진 분류	모델 이름 한 줄로 얼마나 맞힐까?	13장 중 6장. 틀린 이유는 배경, 낯선 각도, 클래스 목록 밖. 제대로 쓰려면 파인튜닝
13	리뷰 감성 분류	글은 어떻게 숫자가 되나?	토큰 → 토큰 ID → 임베딩. 내 데이터와 가까운 데이터로 학습한 모델이 낫다. 대량 정형 작업은 분류 모델, 복합 작업은 LLM

복습 요령: 1일차 노트와 같다. 각 수업 끝의 **학습 목표 점검**을 스스로 설명해 보고, 막히면 해당 섹션으로 돌아가며, 마지막 퀴즈로 마무리한다.

수업 6. 분류로 어느 쪽인지 맞히기

핵심: 분류 결과는 정확도 하나가 아니라 혼동행렬 네 칸과 재현율·정밀도로 읽고, 어느 실수가 더 비싼지가 우선 지표를 정한다.

회귀와 분류

같은 고객 기록으로도 무엇을 묻느냐에 따라 문제가 달라진다. 둘 다 정답이 붙은 데이터로 배우는 지도학습이고, 다른 것은 예측값의 형태다.

질문	답	유형
다음 달 요금은?	$58.30 같은 숫자	회귀
다음 달 해지할까?	예 / 아니오	분류

왜 이탈 예측이 필요한가: 2026년 5월 한 달 번호이동 58만 4,205건. 번호이동은 신청하면 그날 끝나므로 떠나는 순간에는 붙잡을 시간이 없다. 미리 가려내야 한다.

스팸 분류 사례: SKT는 2025년 통신사기 11억 건 차단(스미싱 8.5억 + 스팸전화·보이스피싱 2.5억). KT는 스팸 키워드 등록을 AI로 바꾸며 하루 이상 → 실시간, 차단 건수 +150%.

오류의 두 종류와 레이블 기준

분류 모델이 틀리는 방식은 두 가지고, 두 실수의 무게는 다르다.

실수	스팸 필터 예	결과
정상을 스팸으로	회의 시간 변경 문자 → 스팸함	중요한 연락 누락, 대부분 복구 가능
스팸을 정상으로	택배 주소 불일치 링크 → 받은 문자함	개인정보 유출, 복구 어려움

무엇을 스팸이라 부를지는 모델이 아니라 **사람이 정한다** (광고 문자는 사람마다 답이 갈림). 그 기준으로 붙인 레이블을 보고 모델이 배운다.

양성과 음성, FN과 FP

양성(Positive) = "좋은 쪽"이 아니라 **"찾고 싶은 쪽"**. 무엇을 양성으로 두느냐에 따라 재현율과 정밀도의 뜻이 통째로 바뀐다. Orange3에서는 Target class에서 고른다.

문제	양성 (찾을 대상)	음성
통신사 이탈 예측	이탈 고객	잔류 고객
스팸 필터	스팸	정상 문자

문제	양성 (찾을 대상)	음성
심장 질환 검사	혈관 협착	정상
카드 부정결제 탐지	부정 결제	정상 결제

이탈 예측 테스트 고객 2,113명 (임계값 0.5):

- **FN (거짓 음성, 놓침)** — 실제 이탈인데 잔류로 판정: 245명
- **FP (거짓 양성, 잘못 짚음)** — 실제 잔류인데 이탈로 판정: 157명

산업별로 놓칠 때와 잘못 짚을 때의 피해가 다르다: 카드사(도용 피해 vs 정상 결제 차단), 통신사(해지 vs 불필요한 쿠폰), 제조(불량품 출고 vs 정상품 폐기), 의료(치료 지연 vs 불필요한 재검사).

이탈 예측 오류 비용: 이탈 고객 1명을 놓치면 평균 월요금 $74.4 × 12개월 = **$893** 사라짐. 잔류 고객에게 잘못 연락하면 상담 전화 1회 + 쿠폰 1장. 그래서 이 문제는 놓치지 않는 쪽(재현율)이 더 중요하다.

운영 흐름: 매주 월요일 전체 고객 이탈 확률 산출 → 확률 상위 N명 위험 고객 목록 → 고객관리팀 연락 → 결과 기록 → 재학습.

로지스틱 회귀 (Logistic Regression)

이름에 '회귀'가 들어가지만 **확률을 거쳐 범주를 고르는 분류 모델**이다.

1. **점수** — 특성마다 가중치를 곱해 더함 (선형 회귀와 같은 방식)
2. **확률** — S자 곡선으로 0~100%로 변환 (경계선에서 멀수록 0% 또는 100%에 가까움)
3. **판정** — 임계값을 넘으면 이탈 (고객 C 58% → 임계값 0.5에서 이탈 판정)

결정 경계: 회귀는 점을 따라가는 선, 분류는 두 무리를 가르는 선. 고객이 선의 어느 쪽에 있느냐가 답이다.

임계값 (Threshold)

확률이 이 값을 넘으면 이탈로 판정하는 기준. **사람이 정한다.** 모델은 그대로인데 기준만 옮겨도 판정이 바뀐다.

임계값	고객 A 12%	B 41%	C 58%	D 86%	테스트 2,113명 중 이탈 판정
0.5	잔류	잔류	이탈	이탈	473명
0.3	잔류	이탈	이탈	이탈	811명
0.9	잔류	잔류	잔류	잔류	—

MLU-Explain (mlu-explain.github.io/logistic-regression): 같은 64°F라도 임계값 0.5면 맑은 날, 0.9면 비 오는 날.

이진 분류 (범주 2개: 스팸/정상, 이탈/잔류) vs **다중 분류** (3개 이상: 문의 유형 배송/환불/결제/기타). 오늘 실습은 이진 분류.

정확도의 함정과 혼동행렬

테스트 고객 2,113명 (잔류 1,552, 이탈 561) — 한쪽이 훨씬 적은 **클래스 불균형** 데이터.

모델	정확도	찾은 이탈 고객
A: 전원 잔류로 예측	73.5%	0명
B: 로지스틱 회귀	81.0%	316명

정확도 차이는 7.5%p뿐이지만 잡은 이탈 고객은 0명과 316명. 클래스 불균형에서는 정확도가 성능을 왕곡한다.

혼동행렬 (Confusion Matrix) — 가로줄은 실제, 세로줄은 모델 판정:

	예측 이탈	예측 잔류
실제 이탈 (561)	**TP 316**	**FN 245** (놓친 이탈)
실제 잔류 (1,552)	**FP 157** (불필요한 연락)	**TN 1,395**

TP/FN/FP/TN 읽는 법: 첫 글자는 맞혔는지(T/F), 둘째 글자는 모델의 예측(P 이탈 / N 잔류). FN = "틀렸다, 그리고 잔류라고 했다" = 실제로는 이탈한 고객.

재현율과 정밀도

지표	공식	임계값 0.5	묻는 것	낮을 때 영향
재현율 (Recall)	TP ÷ (TP + FN)	316 ÷ 561 = **56.3%**	실제 이탈 중 모델이 잡은 비율 (분모 = 실제 이탈)	미탐지 고객 이탈
정밀도 (Precision)	TP ÷ (TP + FP)	316 ÷ 473 = **66.8%**	이탈로 예측한 중 실제 이탈 비율 (분모 = 예측 이탈)	불필요한 연락, 쿠폰 비용
정확도 (Accuracy)	(TP + TN) ÷ 전체	1,711 ÷ 2,113 = **81.0%**	전체 중 정답 비율	클래스 불균형 시 왕곡

임계값 0.3으로 내리면 (TP 430, FN 131, FP 381, TN 1,171): 재현율 430 ÷ 561 = **76.6%**, 정밀도 430 ÷ 811 = **53.0%**. 재현율은 오르고 정밀도는 내려간다 — 두 지표는 보통 한쪽이 오르면 다른 쪽이 내려간다.

FDS 오탐지 사례: 카드사가 정상 결제를 부정으로 판정하면(FP) 카드 일시정지. 안내 페이지가 따로 있다는 것은 그만큼 잦다는 뜻. 정밀도가 낮으면 고객센터 문의도 늘어난다.

오류 비용에 따른 지표 선택

문제	미탐지 (FN)	오탐지 (FP)	우선 지표
암 검진	치료 시기 지연	추가 검사 1회	재현율
스팸 필터	스팸 1통 노출	중요 메일 누락	정밀도
부정결제 탐지	도용 피해	정상 결제 차단	둘 다
통신사 이탈	고객 1명 매출 $893	쿠폰 1장, 전화 1통	재현율

현업의 네 가지 질문: "이탈 고객 중 몇 명을 찾았나" → 재현율 / "목록에 오른 고객 중 실제 이탈은 몇 명" → 정밀도 / "아무것도 안 할 때보다 얼마나 나은가" → 기준 모델 비교 / "팀이 감당할 수 있는 목록인가" → 연락 대상 수.

학습 목표 점검

- [ ] 예측값이 수치인지 범주인지로 회귀와 분류를 구분할 수 있다
- [ ] 혼동행렬 네 칸을 읽고 재현율과 정밀도를 계산할 수 있다
- [ ] 오류 비용을 비교해 우선할 평가 지표를 고를 수 있다
- [ ] 임계값을 옮기면 판정이 어떻게 바뀜는지 설명할 수 있다

수업 7. Orange3로 모델 비교하기

핵심: 데이터와 문제는 그대로 두고 모델 위젯만 바꿔 끼우며 성능을 비교한다. 훈련 점수와 교차검증 점수의 차이가 과적합이고, 깊이·k 같은 하이퍼파라미터는 교차검증 점수를 보며 고른다.

heart_disease 데이터셋

Orange3 내장 데이터 (UCI Heart Disease, 클리브랜드 클리닉). 환자 303명, 검사 항목 13개 (나이, 성별, 가슴 통증 유형, 안정 시 혈압, 콜레스테롤, 최대 심박수, 탈륨 검사 등). Target = 심장 혈관 50% 이상 협착 여부, 303명 중 139명 (45.9%).

분류 모델 4종

모델	원리	특징
로지스틱 회귀	경계선을 하나 긋고, 선에서 얼마나 떨어졌는지로 확률	기본 모델
의사결정 트리 (Tree)	"통증 유형이 무증상인가?" 같은 질문을 차례로 던져 가름	판정 이유를 설명할 수 있음

모델	원리	특징
랜덤포레스트	조금씩 다르게 자란 나무 여러 그루가 투표	트리의 약점 보완
kNN (k = 5)	가까운 이웃 k명이 어느 쪽인지 보고 따라감	거리로 판단해 단위 차이에 약함

의사결정 트리의 분기

트리는 **가장 잘 갈리는 질문부터** 던진다. 첫 질문 "탈륨 검사가 정상인가?" 하나로 협착 비율이 22.3% 무리(166명)와 74.5% 무리(137명)로 갈렸다. 그다음 "막힌 혈관 0개?", "통증 무증상?"으로 더 나눴다.

Tree Viewer의 판정 근거: 탈륨 검사 가역적 결손 → 가슴 통증 무증상 → 78명 중 협착 71명 (91.0%). **증상이 없는데도 고위험**이라는 가지가 눈에 띄인다. 대출 심사나 의료처럼 판정 이유를 설명해야 하는 곳에서는 정확도가 조금 낮아도 트리를 고르기도 한다.

교차검증 (Cross-validation)

1일차에는 학습/테스트로 한 번 나눴다. 그런데 환자가 303명뿐이면 누가 테스트에 들어가느냐에 따라 점수가 꽤 달라진다.

1. 303명을 다섯 묶음(한 묶음 약 60명)으로 나눈다
2. 네 묶음으로 학습하고 남은 한 묶음으로 평가한다
3. 평가할 묶음을 바꿔 가며 다섯 번 반복 → 모든 환자가 한 번씩 평가에 쓰인다
4. 다섯 점수의 평균 = 교차검증 점수

Orange3 Test and Score의 기본값이 5겹 교차검증이다.

트리의 약점 두 가지:

약점	증거	대책
깊이를 늘리면 훈련 데이터를 외움 (과적합)	깊이 100 트리: 훈련 95.0% vs 교차검증 75.2%, 차이 19.8%p	깊이 제한
데이터가 조금만 달라져도 첫 질문이 바뀜	재표본 30회의 첫 분기: 탈륨 15회, 통증 무증상 10회, 막힌 혈관 4회, 가역 결손 1회	랜덤포레스트 (나무 여러 그루 다수결)

Orange3 워크플로우와 모델별 결과

흐름: File → Logistic Regression / Tree / kNN → Test and Score → Confusion Matrix, Tree Viewer. CA가 정확도, Recall이 재현율 열.

모델	정확도 (CA)	AUC	재현율	FN (미탐지)
로지스틱 회귀	**84.8%**	0.910	**79.9%**	28명
의사결정 트리	75.2%	0.757	71.2%	40명
kNN	62.0%	0.679	54.0%	64명

(5겹 교차검증, 기본 설정, 협착 환자 139명 기준)

kNN이 약한 이유: 가까운 이웃을 거리로 찾기 때문에, 콜레스테롤처럼 200대인 값과 0과 1인 값이 섞여 있으면 큰 숫자가 거리를 좌우한다 (1일차 스케일링이 필요한 이유).

로지스틱 회귀 혼동행렬: TN 146, FP 18, FN 28, TP 111 → 재현율 111 ÷ 139 = 79.9%, 정밀도 111 ÷ 129 = 86.0%. 통신사 데이터로 본 표와 구조가 똑같다.

데이터에 따른 모델 격차

데이터	최고	최저	격차
heart_disease	로지스틱 84.8%	kNN 62.0%	22.8%p
통신사 이탈	로지스틱 81.0%	랜덤포레스트 78.0%	3%p 이내

같은 모델이라도 데이터가 바뀜면 순위와 격차가 달라진다. 실무에서는 여러 모델을 갈아 끼워 보고 데이터에 맞는 것을 고른다.

학습 파라미터 vs 하이퍼파라미터

	누가 정하나	예
학습 파라미터	모델이 데이터에서 학습	결정 경계의 기울기, 트리의 분기 기준
하이퍼파라미터	사람이 학습 전에 설정	트리 깊이, kNN의 k, 임계값

kNN의 k를 1 → 3 → 5 → 15로 바꾸면 교차검증 정확도가 0.571 → 0.634 → 0.620 → 0.650. **고를 때는 훈련 점수가 아니라 교차검증 점수를 본다.**

Paint Data로 결정 경계 만들기: Labels를 C1, C2로 두 무리 찍기 → Save Data → File로 불러와 Class를 target으로 → Logistic Regression 연결 → Scatter Plot의 Color를 Logistic Regression으로 바꾸면 경계가 점 색으로 보인다.

학습 목표 점검

- [ ] 같은 데이터로 모델만 바꿨을 때 도출되는 성능을 비교할 수 있다

- [ ] Tree Viewer로 트리의 분기 기준을 읽을 수 있다
- [ ] 훈련 점수와 교차검증 점수 차이로 과적합을 판단할 수 있다
- [ ] 학습 파라미터와 하이퍼파라미터를 구분할 수 있다

수업 8. 조용히 떠나는 고객, 미리 찾아내기

핵심: 모델을 고르기 전에 문제 정의서(양성, 기준 모델, 고비용 오류, 목표)를 쓰고, 임계값·가중치·리샘플링으로 소수 클래스를 더 챙기고, 결과는 "몇 명 중 몇 명"으로 보고한다.

임계값과 재현율·정밀도의 상충

MLU-Explain (mlu-explain.github.io/precision-recall): 판정 기준선을 옮기면 재현율과 정밀도가 서로 반대로 움직인다. 재현율을 100%로 만들면 정밀도는 42%로 내려간다.

임계값	탐지	놓침	연락 대상	정밀도	정확도
0.5	316명	245명	473명	66.8%	81.0%
0.3	430명 (+114)	131명	811명 (+338)	53.0%	75.8%

이탈 고객 114명을 더 잡는 대신 연락할 고객이 338명 늘어난다.

F1 점수와 AUC

F1 = 재현율과 정밀도 가운데 **낮은 쪽에 끌려 내려가는** 점수. 정밀도 1.00, 재현율 0.10이면 단순 평균은 0.55지만 F1은 0.18. 0~1 값이라 모델 여러 개를 한 숫자로 비교할 때 쓴다. 통신사 모델: 임계값 0.5에서 0.61, 0.3에서 0.63.

AUC = 임계값을 0부터 1까지 전부 옮겨 보며 매긴 점수. 통신사 모델 **0.845** = 떠난 고객과 남은 고객을 한 명씩 뽑았을 때 떠난 쪽에 더 높은 확률을 줄 가능성이 84.5%. 임계값을 정하기 전에 모델끼리 비교할 때 쓴다.

AUC	뜻
1.0	데이터 누수 의심 (정답을 미리 알려 주는 정보가 특성에 섞임)
0.9	매우 우수
0.7	실무 활용 가능
0.5	무작위 추측 (동전 던지기)

classification_report 읽기

Helpy Code에게 분류 모델을 시키면 보여 주는 표. **양성인 "예" 줄 하나를 먼저 읽는다.**

	precision	recall	f1-score	support
아니오	0.85	0.90	0.87	1552
예	**0.67**	**0.56**	**0.61**	**561**
accuracy			0.81	2113

precision 0.67 = 정밀도 67%, recall 0.56 = 재현율 56%, support 561 = 테스트의 실제 이탈 고객 수. accuracy 0.81은 찍기만 해도 0.73이 나온다는 점을 함께 떠올린다.

평가 지표 선택 순서와 문제 정의서

모델을 고르기 전에 이 순서로 정한다:

1. **"무엇을 찾나"** → 양성 정의
2. **"찍으면 몇 점인가"** → 기준 모델 정확도
3. **"어느 실수가 비싼가"** → 고비용 오류 (FN vs FP)
4. **"어디서 자르나"** → 지표와 임계값

통신사 이탈 예측 문제 정의서	
양성	이탈 고객
기준 모델 정확도	전원 잔류 예측 시 73.5%
고비용 오류	FN, 고객 1명 1년 매출 vs 쿠폰 1장
목표	재현율 최대화, 월 연락 한도 900명 (설명용 가정)

팀장 "이번 달에 누가 떠날 것 같아?" → 데이터 "고객 한 명의 기록으로 다음 달 해지 여부를 예/아니오로 예측" → 모델 "이진 분류, Target 이탈, 양성 이탈 고객".

Telco Customer Churn 데이터

IBM 공개 데이터 한글판 (미국 통신사 샘플, 요금 단위 달러). 고객 7,043명, 열 21개, 이탈 1,869명 (26.5%), 총결제액 빈칸 11개.

열 역할	열	처리
Target	이탈	맞힐 값

열 역할	열	처리
제외	고객번호	사람마다 다 달라 배울 것이 없음
숫자 특성 3개	가입개월, 월요금, 총결제액	그대로 사용
글자 특성 16개	성별, 고령자, 약정형태, 결제수단, 인터넷종류 등	원-핫 인코딩

전처리 3가지: 원-핫 인코딩 / 결측치 처리 (총결제액 빈칸 11개는 모두 가입개월 0인 신규 고객 → 0) / **stratify 분할** (학습 70%와 테스트 30% 양쪽 모두 이탈 비율 26.5% 유지 — 빼면 재현율이 실제보다 좋거나 나쁘게 보일 수 있음).

Helpy Code 지시서 9줄

단계	지시
1 불러오기	통신사_고객이탈.csv 크기와 컬럼명 출력 → (7043, 21)
2 EDA	이탈 비율, 약정형태별·결제수단별 이탈률, 평균 가입개월, 결측치
3 전처리	총결제액 숫자 변환, 결측치 0, 고객번호 제거
4 분할	Target 이탈, 훈련 7 : 테스트 3, stratify
5 기준 모델	전원 안 떠남 정확도
6 학습	로지스틱 회귀, classification_report, 혼동행렬
7 임계값	0.5와 0.3 혼동행렬 비교
8 가중치	class_weight balanced 추가 비교
9 리샘플링	이탈 고객 복제 5:5 후 비교

EDA 결과: 이탈률이 높은 고객 특성

특성	이탈률	비교
월단위 약정	42.7%	1년 11.3%, 2년 2.8%
전자수표 결제	45.3%	우편수표 19.1%, 계좌자동이체 16.7%, 카드자동결제 15.2%
광랜 인터넷	41.9%	DSL 19.0%
기술지원 미가입	41.6%	가입 15.2%

특성	이탈률	비교
고령자	41.7%	그 외 23.6%
가입 6개월 이하	52.9%	평균 가입개월: 이탈 18.0 vs 잔류 37.6

모델이 없어도 "월단위이면서 전자수표" 고객(1,850명, 이탈률 53.7%)부터 연락하면 꽤 많이 맞힌다. 모델은 여기에 19개 열을 한꺼번에 반영한다.

클래스 불균형 대응 3가지

이탈 고객이 26.5%로 적은 데이터에서 소수 쪽을 더 챙기는 방법:

방법	원리	결과 (FN)
임계값 조정	판정 기준을 0.5 → 0.3으로	245 → 131명
가중치 조정 (class_weight)	데이터는 그대로, 틀릴 때 벌점을 다르게. balanced면 잔류 오류 0.68, 이탈 오류 1.88 (약 2.8배)	245 → 114명
리샘플링	적은 쪽을 복제해 26.5% → 50%로 맞춘 뒤 학습 (SMOTE 등)	115명, 재현율 79.5%

복제 리샘플링 결과는 가중치 방식과 거의 같았다 → **원본 데이터를 건드리지 않는 방법부터** 해 본다.

설정별 결과 비교 (연락 한도 900명):

설정	연락 대상	정확도	재현율	놓친 이탈
기준 모델 (전원 잔류)	0명	73.5%	0%	561명
임계값 0.5	473명	81.0%	56.3%	245명
임계값 0.3	811명	75.8%	76.6%	131명
class_weight=balanced	874명	74.4%	**79.7%**	**114명**

연락 한도 안에서 재현율이 가장 높은 **class_weight=balanced**가 답.

모델 교체 vs 임계값 조정: 로지스틱 81.0%, 트리(깊이 5) 79.5%, 랜덤포레스트 78.0% — 모델을 바꿔도 정확도는 3%p 안쪽. 그런데 임계값 하나로 재현율이 56.3% → 76.6%, **+20.3%p**. 모델을 고르는 일보다 무엇을 놓치지 않을지 정하는 일이 결과를 더 크게 바꾼다.

결과 보고 문장

"재현율 79.7%, 정밀도 51.1%, AUC 0.845입니다"라고 보고하면 팀장은 무엇을 하라는 것인지 알기 어렵다. 운영의 말로 바꾼다:

> "다음 달 이탈 예상 고객 **874명**을 선정했습니다. 실제 이탈 **561명 중 447명**이 포함됩니다. 나머지 **427명**은 잔류 고객이라 쿠폰 비용이 추가됩니다."

연락 대상 = TP + FP. 임계값 0.3이면 811명 (= 430 + 381) 중 430명 포함, 381명 잔류 고객.

분류 프로젝트 전체 흐름: 문제 정의 → EDA → 전처리 → 학습 → 평가 → **설정 결정**. 1일차 회귀와 달라진 점: 평가 지표가 늘었고(R^2 하나 → 혼동행렬에서 나온 여러 개), 임계값·가중치 같은 설정을 사람이 정했고, 보고 문장이 "평균 ±291대"에서 "874명 중 447명"으로 바뀌었다.

학습 목표 점검

- [ ] 임계값을 옮길 때 재현율과 정밀도의 변화를 설명할 수 있다
- [ ] 현업 문제를 양성, 기준 모델, 오류 비용, 목표로 정의할 수 있다
- [ ] classification_report에서 필요한 지표를 찾아 읽을 수 있다
- [ ] 모델 결과를 "몇 명 중 몇 명"으로 보고할 수 있다

수업 9. 군집으로 고객 묶기

핵심: 정답 열 없이 데이터의 생김새만 보고 무리를 찾는 것이 군집이고, 그룹의 이름과 할 일은 사람이 붙인다. 채점할 정답이 없으니 기준은 쓸모다.

지도학습과 비지도학습

	지도학습 (Supervised)	비지도학습 (Unsupervised)
질문	"이 고객이 떠날까?"	"고객 유형은 몇 가지인가?"
레이블	있음 (이탈 열)	없음
평가	재현율, 정밀도로 채점	쓸모로 사람이 판단
종류	분류, 회귀	군집, 차원 축소

규칙 기반 세분화 vs 군집: 결제액으로 VIP/골드/실버를 나누는 규칙 기반은 기준이 뚜렷해 설명하기 쉽지만 기준 밖 유형(요금은 낮지만 5년째 쓰는 고객)은 묻힌다. 군집은 여러 열을 함께 보고 묶어 생각하지 못한 유형을 찾지만, 이름은 사람이 붙인다.

k-means 알고리즘 3단계

같은 점을 봐도 몇 무리인지 사람마다 답이 갈린다. 컴퓨터에게 맡기려면 "무엇이 가까운 것인가"를 규칙으로 정해 줘야 하고, 그 규칙이 k-means다.

1. 중심점 k개를 임의로 배치한다

2. 점마다 가장 가까운 중심점에 배정한다
3. 중심점을 그룹 평균으로 옮긴다
4. 중심점이 멈출 때까지 2~3을 반복한다

k는 사람이 정한다. k를 늘릴수록 잘게 쪼개지고 무리 하나하나의 성격은 흐려진다. 정답은 없고, **운영에서 다르게 대응할 수 있는 그룹 수**로 정한다. 처음 중심 위치에 따라 결과가 조금 달라질 수 있다 (naftaliharris.com/blog/visualizing-k-means-clustering에서 직접 움직여 보기).

통신사 고객 7,043명을 4개 군집으로

Helpy Code 지시서 5줄: 가입개월·월요금·총결제액 세 열만 사용 → StandardScaler로 표준화 → k = 4로 k-means, 그룹별 고객 수 → 그룹별 평균 표 → 그룹별 이탈률·약정형태·결제수단 비율 확인. **이탈 열은 묶을 때 쓰지 않고 확인할 때만 쓴다.**

이탈 열을 보지 않고 나눴는데도 이탈률 48.2%인 C 그룹이 따로 떨어져 나왔다.

그룹	세그먼트명	고객 수	평균 가입	월요금	총결제액	이탈률	할 일
A	장기 저가 고객	1,160명	53.6개월	$34.9	$1,836	5.0%	유지 혜택 (이탈률 최저)
B	신규 저가 고객	1,703명	10.2개월	$31.8	$302	24.7%	초기 이탈 방지
C	신규 고가 고객	2,276명	15.4개월	$80.8	$1,251	**48.2%**	약정 전환 제안
D	장기 우량 고객	1,904명	59.5개월	$93.3	$5,549	15.4%	고가 이용자 이탈 관리 (한 명 떠나면 손실 큼)

세그먼트명과 할 일은 평균을 보고 사람이 붙인 것. 정답은 하나가 아니고, 숫자에서 이유를 대면 된다.

고위험 C 그룹 대응 전략: C 그룹 안의 비율 — 월단위 약정 86%, 광랜 인터넷 77%, 전자수표 54%. 그래서 약정 전환 제안(월단위 42.7% vs 2년 2.8%), 결제수단 변경 유도(전자수표 45.3% vs 자동이체 15~17%), 가입 6개월 안에 먼저 연락(6개월 이하 52.9%). **분류는 '누구에게' 연락할지를, 군집은 '무슨 말을' 할지를 알려 준다.**

군집이 틀어지는 3가지 경우

오류	증상	이유
스케일링 누락	그룹이 총결제액 구간으로만 잘림	총결제액 최대 8,684 vs 월요금 최대 118 — 큰 숫자 열이 거리를 거의 다 결정
k 선택 오류	k = 2는 너무 크게, k = 10은 너무 잘게	10개 그룹마다 다른 상품과 연락 방식을 만들 수 없음

오류	증상	이유
해석 누락	"그룹 2, 2,276명"으로만 보고	받은 사람이 무엇을 할지 모름. 그룹마다 이름과 할 일

비지도학습의 다른 활용

활용	내용
차원 축소 (PCA)	30개 열을 두 축으로 압축해 평면에 뿌림. 두 축에 담긴 정보 47%라 요약일 뿐. "가까우면 비슷한 고객"으로만 읽는다, 축 이름은 없다
이상 탐지	군집 중심에서 가장 먼 1% = 71명 (가입 62개월, 월요금 $112.5 최고가 장기 고객). '이상'은 나쁘다는 뜻이 아니라 눈에 띄는 것. 카드 결제, 설비 진동, 서버 로그에 활용
추천	유사 사용자의 선택 추천 (쇼핑, 영상, 음악)
문서 군집	유사 문서 그룹화, 고객센터 문의 분류

2일차 정리: 사람이 정한 값

모델	데이터	결과	평가 지표
회귀	따릉이 대여량	R^2 0.64, MAE 약 290대	R^2, MAE
분류	통신사 이탈, 심장 질환	이탈 561명 중 447명 탐지	혼동행렬, 재현율, 정밀도
군집	통신사 고객 7,043명	고위험 2,276명, 이탈률 48.2%	레이블 없음, 활용성

모델이 정해 주지 않아 사람이 정한 값: **Target** (대여량, 이탈, 혈관 협착) / **양성** (이탈 고객, 질환 환자) / **임계값** (0.5 vs 0.3) / **k** (군집 수 4) / **특성** (시간 원-핫, 고객번호 제외). 3일차 딥러닝은 이 가운데 특성을 스스로 만들어 낸다.

학습 목표 점검

- [ ] 레이블 유무로 지도학습과 비지도학습을 구분할 수 있다
- [ ] k-means가 중심점을 옮기며 군집을 찾는 과정을 설명할 수 있다
- [ ] 군집별 평균을 보고 세그먼트 이름과 액션을 정할 수 있다
- [ ] 스케일링, k 선택, 해석 단계의 오류를 알아챌 수 있다

수업 10. 딥러닝 첫걸음

핵심: 사진과 문장은 사람이 고를 열이 없는 비정형 데이터다. 딥러닝은 다층 신경망이 특성을 스스로 만들고, 학습은 가중치를 고쳐 가는 일이며, 층을 너무 쌓으면 과적합한다.

정형 데이터와 비정형 데이터

1·2일차 데이터는 행과 열로 정리된 정형 데이터였고, 기온·습도·약정 형태처럼 **무엇이 중요할지 열을 고른 것은 사람**이었다. 기준: 사람이 고를 수 있는 열로 정리돼 있으면 정형, 숫자나 글자만 있고 고를 열이 없으면 비정형.

데이터	생김새	유형
따릉이 시간별 대여 기록	시각, 기온, 습도, 대여건수 열	정형
통신사 고객 표	약정, 월요금, 이탈 열	정형
머그컵 사진	224 × 224 × 3 = 숫자 150,528개	비정형
쇼핑몰 리뷰 문장	"와 배송 진짜 빠르네요 3주 걸림 ㅡㅡ"	비정형
자율주행차 카메라 영상	차선, 보행자, 차량이 찍힌 화면	비정형

이미지: 가로 224칸 × 세로 224칸 × RGB 3채널 = 숫자 150,528개. "기온 열은 어디 있지?" 같은 열이 없다. 15만 개 가운데 무엇이 중요한지 사람이 골라 줄 수 없다.

텍스트: "와 배송 진짜 빠르네요 3주 걸림 ㅡㅡ"를 열로 바꾸면 글자 수 21자, 느낌표 0개, "빠르다" 포함 → 예측 긍정. 하지만 실제는 반어법으로 부정. 사람은 바로 알지만 무엇을 보고 알았는지 규칙으로 적기 어렵다.

특성 추출의 주체

	흐름
머신러닝 (1·2일차)	데이터 → **사람이 특성 선택** → 모델 학습 → 예측
딥러닝 (3일차)	데이터 → **모델이 특성을 스스로 만들고 학습** → 예측

통신사 이탈 예측: 사람이 약정·월요금 열을 고름 (머신러닝). 머그컵 사진 분류: 앞쪽 층이 선과 모서리를, 뒤쪽 층이 손잡이 모양을 스스로 만듦 (딥러닝).

퍼셉트론과 다층 신경망

왜 인공 신경망인가: 뇌의 뉴런은 가지돌기로 신호를 받고, 세포체에서 모아, 기준을 넘으면 축삭으로 다음 세포에 보낸다. 1958년 로젠블랫이 이 모양을 본떠 만든 계산 단위가 **퍼셉트론**. 다만 모양만 빌린 이름이고, 실제는 곱하고 더하는 계산이다.

퍼셉트론: 입력마다 가중치를 곱해 더하고, 합이 기준을 넘으면 출력(활성화 함수). 예: 기온 23도 × 0.8 + 시간 18시 × 0.5 + 금요일 × 0.2 → 대여량 152대. 퍼셉트론 하나로는 직선으로 가를 수 있는 단순한 문제만 푼다.

다층 신경망 (Deep Neural Network): 퍼셉트론 여러 개를 나란히 놓으면 층, 층을 여러 개 이어 붙이면 신경망.

층	역할
입력층	이미지 픽셀, 텍스트 토큰
앞쪽 은닉층	선, 모서리 같은 단순한 특징
뒤쪽 은닉층	눈, 바퀴 같은 복잡한 특징
출력층	예측값

학습 원리: 가중치 갱신

가중치 1개 모델 y = a × x. 목표: 2를 넣으면 1이 나오게.

a	출력 (x = 2)	오차	판단
3	6	+5	너무 크다 → 줄인다
1	2	+1	아직 크다 → 줄인다
0.5	1	0	맞는다

출력이 목표보다 크면 a를 줄이고, 작으면 키운다 — 이것이 가중치 갱신의 방향. 모델 구조는 그대로인데 가중치만 바뀜고, 그래서 다른 모델이 된다. 실제 신경망은 이 일을 가중치 수백만 개에 대해 동시에, 아주 작은 걸음으로 반복한다.

가중치 1개 vs 354만 개: 실습 이미지 분류 모델 google/mobilenet_v2_1.0_224의 가중치는 **3,540,265개**. 사람이 찾는 것은 불가능하고 노트북으로 처음부터 학습시키기도 어렵다 → 다른 사람이 찾아 둔 가중치를 빌려 쓴다 (다음 수업).

참고, 진짜 뇌의 크기: 2024년 10월 Nature에 어른 초파리 뇌 전체 배선도 게재 — 뉴런 139,255개, 시냅스 약 5,000만 개 (실습 모델 가중치의 열 배 이상). 사람 뇌 뉴런은 약 860억 개. 같은 달 버클리 팀이 이 지도를 계산 모델로 옮겨 먹이 먹기·더듬이 손질 회로를 예측했고, 2026년 3월 Eon Systems가 가상 초파리 몸에 연결한 영상을 공개 (회사 발표, 논문 심사 없음). "뇌를 복제했다"는 과장이고 배선도 위에 단순한 계산을 얹은 모델. 인공 신경망도 연결과 가중치만으로 판단을 만들어 낸다.

TensorFlow Playground 실습

playground.tensorflow.org — 신경망을 직접 쌓고 학습되는 모습을 보는 연습장. 실행 버튼 / DATA에서 데이터 모양 / HIDDEN LAYER ± 버튼으로 은닉층·뉴런 수 / OUTPUT의 Training loss(훈련 오차)와 Test loss(테스트 오차).

설정	훈련 오차	테스트 오차	결과
원형 데이터, 은닉층 0개	0.496	—	경계가 직선이라 원을 가르지 못함 (과소적합)
원형, 은닉층 1개 뉴런 4개	0.012	—	경계가 휘어 원을 감싼 (적합)
나선형, 은닉층 6개, Noise 35, 훈련 데이터 30%	0.043	0.298	처음 보는 데이터에서 약 7배 더 틀림 (과적합)

(1회 실행 값, 실행마다 다름)

뉴런별 경계선의 조합: 뉴런 하나는 직선 하나 → 뉴런 여러 개는 직선을 합친 곡선 → 층을 더하면 더 복잡한 경계. "앞층은 단순한 특징, 뒷층은 복잡한 특징"이 이것.

은닉층 수와 모델 복잡도: 층이 없으면 직선 하나뿐이라 못 푸는 문제가 있고, 층을 쌓으면 복잡한 모양도 푸지만, 너무 많이 쌓으면 훈련 데이터만 잘 맞히고 새 데이터에서 틀린다. 2일차 결정 트리를 너무 깊게 키우면 외운다던 것과 같다. 모델이 복잡할수록 늘 테스트 데이터로 확인한다.

딥러닝의 차이 한 장 정리

1. **표 데이터** — 사람이 열을 고른다
2. **사진과 문장** — 열이 없다. 모델이 특성을 만든다
3. **깊게 쌓는다** — 앞층은 단순한 특징, 뒷층은 복잡한 특징
4. **학습** — 가중치를 고쳐 가는 일

학습 목표 점검

- [ ] 정형 데이터와 이미지, 텍스트 데이터의 차이를 설명할 수 있다
- [ ] 딥러닝의 특성 자동 추출을 머신러닝과 비교해 설명할 수 있다
- [ ] 가중치 갱신으로 학습 과정을 설명할 수 있다
- [ ] 은닉층 수와 과적합의 관계를 훈련 오차, 테스트 오차로 설명할 수 있다

수업 11. 사전 학습 모델

핵심: 사전 학습 모델은 다른 사람이 많은 데이터로 찾아 둔 가중치를 빌려 학습 없이 바로 쓰는 모델이다. Hugging Face에서 찾고, 무엇으로 학습했는지부터 확인하고, 이미지는 크기와 값 범위를 맞춰 넣고, 성능은 테스트 데이터로 재다.

가중치를 빌려 쓴다

1일차 Teachable Machine은 사진 수십 장으로 몇 분 만에 모델이 됐다. 따릉이는 8,760행이 필요했는데 어떻게? **이미 수많은 이미지로 학습된 층은 손대지 않고 가져다 쓰고, 마지막 층만 내 사진으로 새로 학습**했기 때문.

앞 수업의 y = a × x로 말하면: "2를 넣으면 1이 나오게 하고 싶다" → "a에 0.5를 넣으면 됩니다". 같은 데이터로 학습한 가중치를 알면 학습 없이 바로 쓸 수 있다 = **미리 학습된 가중치 (pretrained weights)**.

모델 개발 3단계와 GPU

단계	내용	누가
1 모델 연구	어떤 구조를 쓸지 탐색, 실험	연구자, 빅테크
2 모델 학습	GPU 수백 대로 며칠씩 데이터로 가중치 찾기	연구자, 빅테크
3 모델 활용	가중치를 불러와 내 데이터에 적용	**이 과정**

좋은 모델 구조와 학습된 가중치만 있다면 1, 2단계는 생략 가능. 우리는 모델마다 데이터를 처리해 입력하고 결과를 해석하는 방법에 집중한다.

GPU (그래픽 처리 장치): 원래 게임 화면을 그리던 칩. 작은 계산을 한꺼번에 수천 개씩 동시에 처리 → 곱하고 더하기를 반복하는 신경망과 잘 맞는다.

	학습	추론
하는 일	가중치 3,540,265개를 처음부터 찾기	학습된 가중치를 사진에 한 번 적용
필요한 것	사진 수백만 장, GPU 여러 대로 며칠	노트북 CPU로 충분

Hugging Face

huggingface.co — 모델을 만든 사람들이 모델과 학습된 가중치를 올려 두는 곳. 공개 모델 **3,072,259개** (캐처 시점). Tasks에서 이미지 분류, 감성 분석, 번역·요약, 음성 인식처럼 하고 싶은 일로 거른다. Qwen, Llama, gpt-oss 같은 LLM도, MobileNet 같은 이미지 분류 모델도 같은 목록에 있다.

모델 페이지에서 학습 데이터 확인 (태그 줄):

실습	모델	학습 데이터 태그	설명
이미지 분류	google/mobilenet_v2_1.0_224	imagenet-1k	ImageNet 1,000개 클래스 사진으로 학습한 가벼운 모델
리뷰 감성 분류	WhitePeak/bert-base-cased-Korean-sentiment	WhitePeak/shopping_review	다국어 BERT를 한국어 쇼핑 리뷰로 파인튜닝

Spaces 데모: Tokenizer Playground ("굳 감사합니다 근데 흘러내려요" 16자 → GPT-4 기준 19토큰), 배경 제거, Whisper Web 음성 인식. 모두 다른 사람이 학습한 가중치를 불러다 쓰는 것.

토큰 (Token): 언어 모델이 글을 읽는 조각. 자주 나오는 말('합니다')은 한 덩어리, 드문 말('굳')은 더 잘게 잘린다. 자르는 도구가 토크나이저.

ImageNet과 파인튜닝

ImageNet: 사진마다 무엇인지 이름표를 붙인 큰 이미지 데이터셋. 실습 모델은 그 중 1,000개 클래스(running shoe, folding chair, espresso, mouse …)로 학습했으므로 **그 1,000개 안에서만 답한다**.

파인튜닝 (Fine-tuning): 이미 학습된 모델을 내 데이터로 조금 더 학습. 1일차 Teachable Machine이 마지막 층만 다시 배운 것이 바로 이것. 리뷰 감성 모델도 다국어 BERT를 한국어 쇼핑 리뷰로 파인튜닝한 것.

모델을 불러와 사용하는 순서

1. **모델 불러오기** — 모델 구조와 가중치를 불러옴
2. **데이터 전처리** — 데이터를 불러와 모델에 넣을 수 있게 전처리
3. **모델 사용** — 데이터를 입력하고, 출력된 값을 모델에 맞게 해석

이미지 데이터와 전처리

이미지 = 픽셀 값 행렬. 픽셀마다 밝기 0~255, 컬러는 빨강·초록·파랑 숫자판 세 장. 준비된 데이터를 있는 그대로 넣을 수 없고, **모델이 학습할 때와 같은 모양**으로 맞춘다.

단계	무엇을	예 (운동화 사진 960 × 695)
1 크기 조정 (Resize)	모델이 받는 크기로	224 × 224
2 숫자 배열 모양	컬러 → 3채널	(224, 224, 3)
3 정규화 (Normalization)	255로 나눠 0~1로	픽셀 186 → 186 ÷ 255 ≈ 0.73

실습에서는 모델과 함께 제공되는 전처리 도구가 이 일을 대신한다.

합성곱 신경망 (CNN)

Convolutional Neural Network. 이미지 분류 모델은 대부분 이 구조 (MobileNetV2도 CNN). 사진 전체를 한꺼번에 보지 않고, **3 × 3 같은 작은 창(커널)을 한 칸씩 옮겨 가며 훑는다**. 창 안의 숫자가 가중치. 창 안 숫자와 이미지 숫자를 곱해 더한 값이 그 자리의 특징 (예: 왼쪽 열 −1, 오른쪽 열 1인 커널 → 세로선에 반응). 앞쪽 층은 선과 모서리, 뒤쪽 층은 무늬와 모양, 마지막에 클래스별 점수. CNN Explainer (poloclub.github.io/cnn-explainer)에서 층별 특징 맵을 볼 수 있다.

ILSVRC와 이미지 분류 모델의 역사: 2012 AlexNet (CNN으로 성능 대폭 향상) → 2014 VGG (깊게 쌓을수록 향상) → 2015 ResNet (아주 깊은 신경망 학습) → 2017 MobileNet (휴대폰에서도 도는 경량) → 2018 MobileNetV2 (실습 모델).

모델 평가와 활용 사례

모델이 학습하지 않은 개·고양이 사진 3장 중 2장을 맞혔다면 정확도 66% — 그것이 처음 보는 사진에서의 실력. 학습한 사진으로 재면 안 된다.

사례	내용
중고나라 AI 상품 등록	사진 → 제목·카테고리·설명 자동 작성. 3개월간 신규 판매자 60% 이상 사용, 등록 시간 약 15% 단축
당근 여러 물건 글쓰기	사진 최대 30장 업로드 → AI가 물건별로 분류 → 판매글 따로 작성
농촌진흥청 병해충 영상진단	31개 작물 병해충 182종 진단, 인식 정확도 평균 95% 이상 (기관 발표)

학습 목표 점검

- [ ] 사전 학습 모델의 개념과 활용 이유를 가중치로 설명할 수 있다
- [ ] Hugging Face에서 모델을 찾아 학습 데이터를 확인할 수 있다
- [ ] 이미지 전처리 과정(크기, 값 범위 조정)을 설명할 수 있다
- [ ] 정확도를 테스트 데이터로 측정해야 하는 이유를 설명할 수 있다

수업 12. 중고거래 상품 사진 분류

핵심: 모델 이름 한 줄로 사전 학습 모델을 불러와 학습 없이 추론만 한다. 모델은 1,000개 클래스 가운데 확률 높은 순으로 답하고, 틀린 이미지는 대개 배경·낯선 각도·목록에 없는 물건 때문이다.

상황과 실습 환경

중고거래 앱 운영팀, 하루 판매글 2만 건. 카테고리를 직접 고르게 하면 절반은 엉뚱한 곳에 올린다. "사진만 올려도 카테고리가 자동으로 붙게 할 수 없나요?" 가진 것: 사진 13장과 모델 이름 하나.

항목	내용
모델	google/mobilenet_v2_1.0_224 (ImageNet 1,000개 클래스로 학습)
속도	13장 약 10초, GPU 없이 노트북 CPU
코드	직접 쓰는 코드 0줄, Helpy Code에 프롬프트로 지시

Helpy Code 프롬프트 6줄: 데이터 확인 (사진 몇 장) → 모델 로드 → 단일 추론 (운동화.jpg 상위 3개) → 전체 추론 (파일 이름, 1등 답, 확률 표) → 번역 (영어 → 한국어) → 추가 이미지 (내가 찍은 사진).

Top-3 예측 결과 읽기

모델은 1,000개 클래스 각각에 확률을 매기고 높은 것부터 보여 준다. **1위 확률이 높을수록 모델이 확신**한다는 뜻.

사진	1위	2위	3위	읽기
운동화	running shoe 81%	clog 4%	loafer 4%	확신 높음, 정답
우산	sundial (해시계) 30.9%	coil 6.2%	umbrella 3.7%	확신 낮음, 정답은 3위

둥근 판에 살이 뻗은 우산 모양이 해시계와 비슷해 보였을 수 있다. 모델은 사람처럼 물건을 아는 것이 아니라 **학습한 1,000가지 사진과 생김새를 비교**한다. 1위가 낮으면 모델도 헷갈린다는 뜻이니 사람이 한 번 더 봐야 하고, Top-3를 함께 보면 틀린 답 아래 숨은 정답을 찾을 수 있다 (텐트도 1위 유르트, 2위 산악용 텐트).

오늘의 결과: 13장 중 6장

정분류 (6장)	오분류 (7장, 모델의 1위 답)
운동화 running shoe 81%	백팩 → vacuum (진공청소기) 80%
캠핑의자 chair 99%	우산 → sundial 31%
무선마우스 mouse 90%	이어폰 → control (리모컨) 27%
키보드 keyboard 77%	충전케이블 → hair slide (머리핀) 37%
선글라스 sunglasses 54%	손목시계 → stopwatch 58%
헤어드라이어 hair dryer 46%	텐트 → yurt 41%, 머그컵 → shaker 53%

백팩은 진공청소기라고 80%나 확신하며 틀렸다. **확률이 높다고 늘 맞는 것은 아니다** — 사람이 결과를 사진과 맞춰 보는 일이 필요하다.

오분류 원인 3가지

원인	예	해결
배경에 다른 물건	백팩 + 등산 스틱 → 진공청소기 80%	사진을 다시 찍으면 나아질 수 있음
낯선 촬영 각도	학습 사진에 없던 방향, 거리, 조명	사진을 다시 찍으면 나아질 수 있음
클래스 목록에 없는 물건	무선 이어폰 → 리모컨 27%, 충전 케이블 → 머리핀 37%	아무리 좋은 모델도 못 맞힘. 내 카테고리로 **파인튜닝** 필요

1,000개 목록은 2012년 ImageNet 대회(ILSVRC) 때 정해진 것. 운영팀 요청대로 쓰려면 앱의 카테고리에 맞는 이미지로 추가 학습해야 한다.

학습 목표 점검

- [ ] 사전 학습 모델로 이미지 분류를 Helpy Code에 지시할 수 있다
- [ ] Top-3 예측 결과와 확률을 해석할 수 있다
- [ ] 오분류 이미지의 원인을 설명할 수 있다

수업 13. 리뷰 감성 분류

핵심: 텍스트는 토큰 → 토큰 ID → 임베딩을 거쳐 숫자가 된다. 감성 모델은 내 일과 가까운 데이터로 학습한 것을 고르고 재현율로 비교한다. 답이 정해진 일을 대량으로 할 때는 분류 모델, 여러 일을 한 번에 시킬 때는 LLM.

텍스트가 숫자가 되는 길

이미지는 칸마다 밝기 숫자가 처음부터 있었지만, 텍스트에는 숫자가 하나도 없고 리뷰마다 길이도 제각각. 게다가 **시퀀스 데이터** — "나는 고양이를 키운다"와 "고양이는 나를 키운다"는 같은 단어인데 뜻이 다르므로 순서도 함께 담아야 한다.

텍스트 입력 처리 4단계:

1. **토큰화** — "굳 감사합니다 근데 흘러내려요"를 실습 모델로 쪼개면 12개 토큰 (굳 / 감 / 사 / 합 / 니다 / 근 / 데 / 흘 / 러 / 내 / 려 / 요). 어떤 단위로 쪼개는지는 모델마다 다르다 (GPT-4 토크나이저는 19 토큰)
2. **토큰 ID** — 토큰마다 모델 사전의 번호 (굳 8911, 감 8848 …)
3. **임베딩** — 번호마다 정해진 길이의 숫자 묶음 (토큰마다 숫자 768개)
4. **모델 입력** — 이제 이미지처럼 숫자만 들어간다

원-핫 인코딩 vs 임베딩

	원-핫 인코딩	임베딩 (Embedding)
표현	단어마다 칸 하나에 1, 나머지 0	단어마다 수백 개 숫자로 된 좌표
길이	사전 토큰 수만큼 (실습 모델 119,547칸, 한 칸만 1)	정해진 길이 (768칸), 단어 수와 무관
의미	없음 — "좋아요", "만족", "최악" 어느 둘을 비교해도 겹치는 칸 0	뜻이 가까운 단어는 가까운 좌표
학습	"좋아요"를 배워도 "만족"은 처음부터	하나만 배워도 다른 하나를 짐작

"좋아요"와의 코사인 유사도 (1에 가까울수록 의미가 가까움, 실습 모델 768차원 임베딩): 만족 **0.99**, 최고 0.57, 배송 0.57, 별로 0.13, 최악 0.14. 숫자 768개 안에 뜻이 담겨 있다. 2차원으로 줄여 그리면 칭찬하는 말은 오른쪽, 불만은 왼쪽에 모인다.

쇼핑몰 부정 리뷰 우선 대응

하루 리뷰 수백 건, 화난 손님의 리뷰부터 먼저 답하고 싶다. 2일차 이탈 예측과 같은 구조:

항목	값
양성	부정 리뷰 (찾고 싶은 쪽)
고비용 오류	FN — 화난 손님을 놓치면 떠난다. FP는 한 번 더 읽으면 됨
목표 지표	재현율 (부정 리뷰 중 몇 %를 잡았나)
정확도 함정	긍부정 반반이면 모두 긍정이라 답해도 50%

데이터: 네이버 쇼핑 리뷰 20만 건 (bab2min/corpus, 퍼블릭 도메인). 별점 1~2는 부정, 4~5는 긍정 (3점 없음). 긍정 1,000 + 부정 1,000 = 2,000건 사용, 평균 약 40자.

Helpy Code 프롬프트 6줄: csv 읽고 긍부정 개수 → 모델 A로 한 줄 판정 → 2,000건 전부 판정, 정확도·재현율·정밀도 → 혼동행렬 → 모델 B로 똑같이 하고 비교 → 틀린 리뷰 확신 높은 순 10개.

모델 A vs 모델 B

	모델 A matthewburke/korean_sentiment	모델 B WhitePeak/bert-base-cased-Korean-sentiment
학습 데이터	태그·설명 없음 (예시가 "영화 재밌다"라 다른 글로 학습했을 가능성)	다국어 BERT를 한국어 쇼핑 리뷰로 파인튜닝

	모델 A matthewburke/korean_sentiment	모델 B WhitePeak/bert-base-cased-Korean-sentiment
TP / FN / FP / TN	816 / 184 / 38 / 962	923 / 77 / 59 / 941
정확도	88.9%	**93.2%**
재현율	81.6%	**92.3%**
정밀도	**95.6%**	94.0%
놓친 부정 리뷰	184건	**77건** (58% 감소)

같은 일을 하는 모델이라도 **무엇으로 학습했는지**에 따라 성능이 다르다. 내 데이터와 가까운 데이터로 학습한 모델을 고르고, 고를 때는 목표 지표인 재현율을 먼저 본다.

레이블 오류: 모델이 틀렸다고 나온 리뷰를 꺼내 보면 "모든면에서 만족합니다"가 별점 1점, "ㅎ포장이 진짜 별로에요ㅠㅠ"가 5점. 우리가 정답이라 부른 것은 손님이 누른 별점일 뿐. **지표만 보지 말고 틀린 예를 직접 읽는다.**

모델 B를 속이는 리뷰: "와 배송 진짜 빠르네요 3주 걸림 ——" → 모델 B는 긍정 95%. 반어법, 신조어, ㅋㅋ·ㅎㅎ 섞기가 잘 통한다. 같은 문장을 ChatGPT에 넣으면 대개 반어법을 알아채고 부정이라고 답한다.

분류 모델 vs LLM

LLM (대형 언어 모델) = 문장에서 다음에 올 토큰의 확률을 계산하는 언어 모델. 확률 높은 토큰을 고르고 이어 붙이고 반복해 문장을 만든다. 다음 단어 맞히기를 엄청나게 많은 글로 배웠다.

	분류 모델	LLM (ChatGPT 등)
학습 데이터	쇼핑 리뷰	웹 텍스트 수조 토큰
학습 목표	긍정·부정 분류	다음 토큰 예측
커버하는 표현	리뷰에 나온 표현	반어법, 신조어 포함
출력	클래스 2개 중 1개	요약, 번역, 답장 등
실행	내 노트북에 내려받아 실행, 추가 요금 없음	회사 서버의 모델에 **API**로 요청, 토큰 수만큼 요금
리뷰 2,000건	2~4분, 0원, 같은 입력에 늘 같은 답	요청 2,000회, 토큰 약 10만 개, 같은 입력에도 답이 바뀔 수 있음

API = 다른 프로그램이나 서비스의 기능을 내 프로그램에서 불러 쓰는 창구. LLM은 너무 커서 내려받기 어려우므로 회사 서버에 인터넷으로 질문을 보내고 답을 받는다.

용도별 선택 기준: 답이 정해진 일을 대량으로 → 분류 모델. 요약·답장처럼 여러 일을 한 번에 → LLM. 둘을 같이 쓰기도 한다: 리뷰 2,000건 → 분류 모델 → 부정 리뷰 → LLM → 답장 초안.

할 일	선택
쇼핑몰 리뷰 2,000건을 긍정·부정으로	분류 모델
부정 리뷰에 보낼 사과 답장 초안	LLM
매일 문의를 배송·환불·결제·기타로	분류 모델
한 주 부정 리뷰의 공통 불만 요약	LLM

학습 목표 점검

- [ ] 텍스트가 토큰, 토큰 ID, 임베딩을 거쳐 숫자가 되는 과정을 설명할 수 있다
- [ ] 원-핫 인코딩과 임베딩의 차이를 설명할 수 있다
- [ ] 두 감성 분류 모델을 혼동 행렬과 재현율로 비교해 선택할 수 있다
- [ ] 분류 모델과 LLM 가운데 상황에 맞는 것을 선택할 수 있다

3일 과정 전체 정리

사흘 내내 같은 순서였다: **문제를 정하고 → 데이터를 보고 → 모델을 고르고 → 목적에 맞는 지표로 결과를 읽는다.**

일차	주제	질문	데이터	평가
1	회귀	따릉이가 한 시간에 몇 대 빌려질까	정형 (표)	R^2, MAE
2	분류, 군집	누가 떠날까, 누구끼리 비슷할까	정형 (표)	혼동행렬, 재현율, 정밀도 / 활용성
3	딥러닝	사진과 리뷰 글을 어떻게 분류할까	비정형 (이미지, 텍스트)	Top-3 확률, 재현율

문제 유형 판단 기준

새 문제를 만나면 두 가지를 먼저 묻는다.

1. 데이터가 표인가?

- 예 (정형 데이터) → 1·2일차 방법. 사람이 특성을 고른다
- 아니오 (이미지, 텍스트) → 3일차처럼 사전 학습 모델을 빌려 쓴다

2. 무엇을 맞히나?

답	유형	예
숫자	회귀	대여건수
범주	분류	이탈, 리뷰 감성
정답 없음	군집	고객 세분화

그리고 지표는 마지막에 늘 **목적에 맞게** 고른다.

모델이 아니라 사람이 정한 값

값	예	어디서
Target	대여량, 이탈, 혈관 협착	1·2일차
양성 (찾고 싶은 쪽)	이탈 고객, 질환 환자, 부정 리뷰	2·3일차
임계값	0.5 vs 0.3	2일차
가중치 조정	class_weight=balanced	2일차
k (군집 수)	4	2일차
특성	시간 원-핫, 고객번호 제외	1·2일차 (3일차 딥러닝은 스스로)
어떤 사전 학습 모델을 쓸지	학습 데이터가 내 데이터와 가까운 것	3일차
분류 모델 vs LLM	대량 정형 작업 vs 복합 작업	3일차

1일차와 달라진 점

	1일차 회귀	2일차 분류	3일차 딥러닝
평가 지표	R^2, MAE 두 개	혼동행렬에서 나온 여러 개 (재현율, 정밀도, F1, AUC)	같은 분류 지표 + Top-k 확률
사람이 정하는 설정	특성	임계값, 가중치, k	어떤 모델을 빌릴지

	1일차 회귀	2일차 분류	3일차 딥러닝
보고 문장	"평균 ±291대"	"874명 중 447명"	"13장 중 6장, 파인튜닝 필요"
특성은 누가	사람	사람	모델

핵심 용어 사전

배운 순서대로. 1일차 노트에 이미 있는 용어(특성, 타깃, 가중치, 손실, 과적합, MAE, R^2, 원-핫 인코딩 등)는 빼고 2·3일차에 새로 나온 것만.

용어	영어	한 줄 정의
양성 / 음성	Positive / Negative	양성은 "찾고 싶은 쪽" (이탈 고객, 스팸, 부정 리뷰). 좋고 나쁨과 무관
혼동행렬	Confusion Matrix	모델 결과를 TP, FN, FP, TN 네 칸으로 나눠 센 표. 가로줄 실제, 세로줄 예측
TP / TN	True Positive / Negative	맞혔다 + 양성/음성으로 예측
FN	False Negative, 거짓 음성	틀렸다 + 음성으로 예측 = 실제 양성을 **놓침**
FP	False Positive, 거짓 양성	틀렸다 + 양성으로 예측 = 실제 음성을 **잘못 짚음**
재현율	Recall	TP ÷ (TP + FN). 실제 양성 중 모델이 잡은 비율. 놓치지 않았나
정밀도	Precision	TP ÷ (TP + FP). 양성 예측 중 실제 양성 비율. 찾은 게 진짜나
정확도	Accuracy	(TP + TN) ÷ 전체. 클래스 불균형에서는 속기 쉬움
F1 점수	F1 score	재현율과 정밀도 중 낮은 쪽에 끌려 내려가는 점수. 모델 여러 개를 한 숫자로 비교
AUC	Area Under the Curve	임계값을 0~1 전부 옮겨 보며 매긴 점수. 0.5 동전 던지기, 0.7 실무 가능, 0.9 매우 우수, 1.0 데이터 누수 의심
데이터 누수	Data leakage	정답을 미리 알려 주는 정보가 특성에 섞여 들어간 경우. AUC가 1.0에 가까워짐

용어	영어	한 줄 정의
클래스 불균형	Class Imbalance	한쪽 클래스가 훨씬 적은 데이터 (이탈 26.5%). 전원 한쪽으로 찍어도 정확도가 높음
임계값	Threshold	확률이 이 값을 넘으면 양성으로 판정하는 기준. 사람이 정함
로지스틱 회귀	Logistic Regression	점수 → S자 곡선으로 확률 → 임계값으로 판정하는 분류 모델
결정 경계	Decision Boundary	분류 모델이 두 무리를 가르는 선
이진 / 다중 분류	Binary / Multi-class	범주 2개 / 3개 이상
의사결정 트리	Decision Tree	가장 잘 갈리는 질문부터 차례로 던져 가르는 모델. 판정 이유 설명 가능
랜덤포레스트	Random Forest	조금씩 다르게 자란 트리 여러 그루의 다수결
kNN	k-Nearest Neighbors	가까운 이웃 k명을 보고 따라감. 거리 기반이라 단위 차이에 약함
교차검증	Cross-validation	데이터를 k묶음으로 나눠 번갈아 평가하고 평균. 데이터가 적을 때 점수가 흔들리는 것을 막음
하이퍼파라미터	Hyperparameter	사람이 학습 전에 정하는 값 (트리 깊이, k, 임계값). 모델이 배우는 학습 파라미터와 구분
classification_report	—	클래스별 precision, recall, f1-score, support를 보여 주는 표. 양성 줄부터 읽음
support	—	테스트에 있는 그 클래스의 실제 개수
stratify 분할	—	학습/테스트로 나눌 때 클래스 비율을 양쪽 똑같이 유지
가중치 조정	class_weight	데이터는 그대로, 소수 클래스를 틀릴 때 벌점을 더 크게
리샘플링	Resampling	소수 클래스를 복제하거나 다수를 줄여 비율을 맞춤 (SMOTE 등)
기준 모델	Baseline	아무것도 배우지 않고 전부 한쪽으로 찍는 모델. 이것부터 이겨야 함
지도 / 비지도학습	Supervised / Unsupervised	정답 열이 있다 / 없다

용어	영어	한 줄 정의
군집	Clustering	정답 없이 데이터의 생김새만 보고 무리를 찾는 일
k-means	—	중심점 k개 배치 → 가까운 중심에 배정 → 중심을 평균으로 이동, 반복
중심점	Centroid	각 군집의 가운데
세그먼트	Segment	군집에 사람이 이름과 할 일을 붙인 것 (신규 고가 고객)
표준화	StandardScaler	평균 0, 표준편차 1로. 군집 전에 필수 — 없으면 큰 숫자 열이 그룹을 결정
차원 축소 (PCA)	Dimensionality Reduction	열 수십 개를 두 축으로 압축해 평면에 그림. 요약일 뿐, 축 이름 없음
이상 탐지	Anomaly Detection	군집 중심에서 멀리 떨어진 것 찾기. '이상'은 눈에 띄는 것, 나쁘다는 뜻 아님
정형 / 비정형 데이터	Structured / Unstructured	사람이 고를 열로 정리된 표 / 숫자나 글자만 있고 고를 열이 없는 사진·문장·영상
딥러닝	Deep Learning	여러 층의 신경망이 특성을 스스로 만들고 학습
퍼셉트론	Perceptron	입력마다 가중치를 곱해 더하고 기준을 넘으면 출력하는 가장 작은 계산 단위 (1958, 로젠블랫)
활성화 함수	Activation Function	퍼셉트론에서 넘을지 말지 정하는 부분
은닉층	Hidden Layer	입력층과 출력층 사이의 층. 앞쪽은 단순한 특징, 뒤쪽은 복잡한 특징
훈련 오차 / 테스트 오차	Training / Test loss	두 값의 차이가 크면 과적합
사전 학습 모델	Pre-trained Model	다른 사람이 많은 데이터로 찾아 둔 가중치를 빌려 바로 쓰는 모델
파인튜닝	Fine-tuning	이미 학습된 모델을 내 데이터로 조금 더 학습 (마지막 층만 다시)
추론	Inference	학습된 가중치를 새 데이터에 한 번 적용. CPU로 충분
GPU	Graphics Processing Unit	작은 계산을 수천 개씩 동시에 처리하는 칩. 학습에 필요

용어	영어	한 줄 정의
Hugging Face	—	모델과 학습된 가중치를 공유하는 저장소. Spaces에서 바로 실행
ImageNet	—	사진마다 이름표를 붙인 큰 이미지 데이터셋. 1,000개 클래스 (ILSVRC)
CNN	Convolutional Neural Network	작은 창(커널)으로 사진을 훑어 특징을 뽑는 층을 쌓은 신경망
커널	Kernel	CNN의 3 × 3 같은 작은 창. 창 안 숫자가 가중치
픽셀	Pixel	이미지의 가장 작은 칸. 밝기 0~255
크기 조정 / 정규화	Resize / Normalization	224 × 224로 맞추고 255로 나눠 0~1로
Top-k	—	확률 높은 상위 k개 답
토큰 / 토크나이저	Token / Tokenizer	언어 모델이 글을 읽는 조각 / 자르는 도구. 모델마다 다름
토큰 ID	—	토큰마다 붙는 모델 사전의 번호
임베딩	Embedding	토큰마다 정해진 길이의 숫자 묶음(좌표). 뜻이 가까운 단어는 가까운 좌표
코사인 유사도	Cosine Similarity	두 임베딩이 얼마나 비슷한지. 1에 가까울수록 가까움
시퀀스 데이터	Sequence Data	순서가 뜻을 정하는 데이터 (텍스트)
BERT	—	텍스트를 읽는 사전 학습 모델. 다국어판을 한국어 리뷰로 파인튜닝해 사용
LLM	Large Language Model	다음 토큰 확률을 계산해 문장을 만드는 언어 모델 (ChatGPT 등)
API	Application Programming Interface	다른 프로그램·서버의 기능을 불러 쓰는 창구. LLM은 회사 서버에 요청, 토큰만큼 요금
레이블 오류	Label error	정답이라 부른 값 자체가 틀린 경우 (별점을 잘못 누른 리뷰)

꼭 기억할 숫자

이 숫자를 보고 어느 장면인지 떠올리면 복습이 된 것이다.

숫자	무엇	어디서
7,043명 / 1,869명 (26.5%)	통신사 고객 전체 / 이탈 고객	수업 6, 8, 9
2,113명 (잔류 1,552, 이탈 561)	테스트 고객 30%	수업 6, 8
73.5%	전원 잔류로 찍은 기준 모델 정확도 (이탈 0명 찾음)	수업 6, 8
TP 316 / FN 245 / FP 157 / TN 1,395	임계값 0.5 혼동행렬	수업 6
56.3% / 66.8% / 81.0%	임계값 0.5의 재현율 / 정밀도 / 정확도	수업 6
76.6% / 53.0% / 75.8%	임계값 0.3의 재현율 / 정밀도 / 정확도	수업 6, 8
473명 → 811명	임계값 0.5 → 0.3일 때 연락 대상	수업 6, 8
$893	이탈 고객 1명을 놓칠 때 1년 매출 ($74.4 × 12)	수업 6
0.845	통신사 모델 AUC	수업 8
0.68 / 1.88	class_weight=balanced의 잔류 / 이탈 오류 벌점 (약 2.8배)	수업 8
874명 중 447명	가중치 조정 모델의 보고 문장 (재현율 79.7%, 놓침 114명)	수업 8
+20.3%p vs 3%p 이내	임계값 조정으로 오른 재현율 vs 모델 교체로 바뀜 정확도	수업 8
42.7% / 45.3% / 52.9%	월단위 약정 / 전자수표 / 가입 6개월 이하 이탈률	수업 8, 9
303명 / 139명	heart_disease 환자 / 협착 환자	수업 7
84.8% / 75.2% / 62.0%	로지스틱 / 트리 / kNN 교차검증 정확도 (격차 22.8%p)	수업 7
95.0% vs 75.2%	깊이 100 트리의 훈련 vs 교차검증 정확도 (과적합 19.8%p)	수업 7
k = 4, C 그룹 2,276명, 48.2%	군집 수, 고위험 그룹 인원과 이탈률	수업 9
8,684 vs 118	총결제액 최대 vs 월요금 최대 — 표준화가 필요한 이유	수업 9
224 × 224 × 3 = 150,528	이미지 한 장의 숫자 개수	수업 10, 11
a = 0.5	y = a × x에서 2 → 1이 나오는 가중치	수업 10, 11
3,540,265개	google/mobilenet_v2_1.0_224의 가중치	수업 10, 11

숫자	무엇	어디서
139,255개 / 약 5,000만 개 / 860억 개	초파리 뇌 뉴런 / 시냅스 / 사람 뇌 뉴런	수업 10
0.496 → 0.012	은닉층 0개 → 1개일 때 훈련 오차 (원형 데이터)	수업 10
0.043 vs 0.298	은닉층 6개의 훈련 vs 테스트 오차 (과적합, 약 7배)	수업 10
3,072,259개	Hugging Face 공개 모델 수 (캐처 시점)	수업 11
1,000개	ImageNet 클래스 (2012 ILSVRC)	수업 11, 12
186 ÷ 255 ≈ 0.73	픽셀 정규화	수업 11
13장 중 6장	상품 사진 분류 정답	수업 12
81% vs 31%	운동화 1위 확률 (확신) vs 우산 → 해시계 1위 확률 (헷갈림)	수업 12
16자 → 12토큰 (또는 19토큰)	"굳 감사합니다 근데 흘러내려요" — 실습 모델 / GPT-4 토크나이저	수업 11, 13
119,547칸 vs 768칸	원-핫 인코딩 vs 임베딩 길이 (실습 모델)	수업 13
0.99	"좋아요"와 "만족"의 임베딩 유사도	수업 13
2,000건 (1,000 + 1,000)	리뷰 감성 분류 실습 데이터	수업 13
184건 → 77건	놓친 부정 리뷰, 모델 A → 모델 B (58% 감소)	수업 13
81.6% → 92.3%	재현율, 모델 A → 모델 B	수업 13
2~4분, 0원	리뷰 2,000건, 노트북의 분류 모델	수업 13

셀프 체크 퀴즈

먼저 답을 적어 보고 아래 정답 표와 맞춰 본다. 틀린 문항의 '복습 위치'로 돌아가면 된다.

문제

1. 같은 고객 기록으로 "다음 달 요금은?"과 "다음 달 해지할까?"는 각각 어떤 문제인가?
2. 분류에서 '양성'은 무엇을 뜻하나? 이탈 예측과 스팸 필터에서 양성은 각각 무엇인가?
3. FN과 FP를 두 글자를 따로 읽어 설명하시오. 이탈 예측에서 각각 무슨 실수인가?
4. TP 316, FN 245, FP 157, TN 1,395일 때 재현율과 정밀도는? (분모가 어느 칸의 합인지 먼저 정할 것)
5. 전원 잔류라고 찍어도 정확도가 73.5%인 이유는? 이런 데이터를 무엇이라 부르나?
6. 암 검진, 스팸 필터, 통신사 이탈 예측에서 각각 우선할 지표는? 이유는?

7. 로지스틱 회귀는 왜 이름에 '회귀'가 들어가는데 분류 모델인가? 세 단계로 설명하시오.
8. 떠날 확률 58%인 고객은 임계값 0.5와 0.9에서 각각 어떻게 판정되나? 임계값을 0.5에서 0.3으로 내리면 재현율과 정밀도는 어느 방향으로 움직이나?
9. 교차검증이란 무엇이고 왜 필요한가? 훈련 95.0%, 교차검증 75.2%인 트리는 어떤 상태인가?
10. 하이퍼파라미터와 학습 파라미터의 차이는? 각각 예를 두 개씩 드시오. 하이퍼파라미터를 고를 때 보는 점수는?
11. kNN이 heart_disease에서 가장 약한 이유는?
12. AUC 0.5, 0.7, 0.9, 1.0은 각각 무엇을 뜻하나?
13. classification_report에서 어느 줄을 먼저 읽나? support 561은 무엇인가?
14. 문제 정의서의 네 항목은? 통신사 이탈 예측에 맞게 채우시오.
15. 클래스 불균형 대응 3가지는? 연라 한도 900명 안에서 가장 많이 잡은 설정은?
16. "재현율 79.7%, 정밀도 51.1%"를 운영의 말로 바꾸어 세 문장으로 보고하시오.
17. 지도학습과 비지도학습을 가르는 기준은? 비지도학습은 어떻게 평가하나?
18. k-means 3단계를 설명하시오. k는 누가, 무엇을 기준으로 정하나?
19. 군집 전에 표준화를 빼면 무슨 일이 생기나? (총결제액과 월요금의 최댓값으로 설명)
20. "그룹 2, 2,276명"이라는 보고는 무엇이 빠졌나? 분류와 군집은 각각 운영에 무엇을 알려 주나?
21. 정형 데이터와 비정형 데이터를 가르는 기준은? 224 × 224 컬러 사진은 숫자 몇 개인가?
22. 머신러닝과 딥러닝에서 특성은 각각 누가 만드나?
23. y = a × x에서 x = 2를 넣어 1이 나오게 하려 한다. a = 2로 시작하면 오차는 얼마이고 a를 키워야 하나 줄여야 하나?
24. TensorFlow Playground에서 은닉층 0개는 왜 원형 데이터를 못 가르나? 은닉층 6개에서 훈련 오차 0.043, 테스트 오차 0.298은 무슨 상태인가?
25. Teachable Machine은 사진 수십 장으로 어떻게 모델이 됐나? 이 방법의 이름은?
26. 학습과 추론의 차이는? 각각 GPU가 필요한가?
27. Hugging Face 모델 페이지에서 가장 먼저 확인해야 할 것은? 실습 모델 두 개의 학습 데이터 태그는?
28. 960 × 695 사진을 실습 모델에 넣으려면 거치는 세 단계는? 픽셀 값 186은 얼마가 되나?
29. CNN의 커널이란? 커널 안의 숫자는 무엇인가?
30. 우산 사진의 1위 답이 해시계 31%였다. 이 결과를 어떻게 읽어야 하나? Top-3를 함께 보는 이유는?
31. 오분류 원인 3가지는? 무선 이어폰이 리모컨으로 나온 것은 어느 원인이고 어떻게 해결하나?
32. 텍스트가 모델에 들어가기까지의 4단계는?
33. 원-핫 인코딩과 임베딩의 차이 두 가지는? (길이, 의미)
34. 리뷰 감성 모델 A와 B 중 무엇을 고르고, 왜 그런가? 정밀도는 A가 높은데도?
35. "와 배송 진짜 빠르네요 3주 걸림 ㅡㅡ"를 분류 모델과 ChatGPT는 각각 어떻게 판정하나? 왜 다른가?

36. 리뷰 2,000건 긍부정 분류 / 부정 리뷰 사과 답장 초안 / 한 주 부정 리뷰 공통 불만 요약 — 각각 분류 모델과 LLM 중 무엇으로?

정답

번호	정답	복습 위치
1	요금은 숫자 → 회귀. 해지 여부는 예/아니오 → 분류. 둘 다 지도학습	수업 6 · 회귀와 분류
2	"찾고 싶은 쪽" (좋은 쪽이 아님). 이탈 고객 / 스팸	수업 6 · 양성과 음성
3	첫 글자는 맞혔는지(T/F), 둘째는 모델 예측(P/N). FN = 틀렸고 잔류라 함 = 이탈 고객을 놓침. FP = 틀렸고 이탈이라 함 = 잔류 고객을 잘못 짚음	수업 6 · 혼동행렬
4	재현율 316 ÷ (316 + 245) = 56.3%. 정밀도 316 ÷ (316 + 157) = 66.8%	수업 6 · 재현율과 정밀도
5	잔류가 1,552명으로 대부분이라 (1,552 ÷ 2,113). 클래스 불균형	수업 6 · 정확도의 함정
6	암 검진 재현율 (놓치면 치료 지연), 스팸 필터 정밀도 (중요 메일 누락이 더 비싸서), 통신사 이탈 재현율 (고객 1명 $893 vs 쿠폰 1장)	수업 6 · 지표 선택
7	① 선형 회귀처럼 특성 × 가중치를 더해 점수 ② S자 곡선으로 0~100% 확률 ③ 임계값을 넘으면 양성 판정. 확률을 거쳐 범주를 고르므로 분류	수업 6 · 로지스틱 회귀
8	0.5에서 이탈, 0.9에서 잔류. 임계값을 내리면 재현율↑ 정밀도↓ (56.3 → 76.6%, 66.8 → 53.0%)	수업 6, 8 · 임계값
9	데이터를 5묶음으로 나눠 4로 학습, 1로 평가를 5번 반복해 평균. 데이터가 적을 때 누가 테스트에 들어가느냐에 따라 점수가 흔들리므로. 19.8%p 차이 = 과적합	수업 7 · 교차검증
10	하이퍼파라미터는 사람이 학습 전에 정함 (트리 깊이, k, 임계값). 학습 파라미터는 모델이 데이터에서 배움 (경계 기울기, 분기 기준). 교차검증 점수	수업 7 · 하이퍼파라미터
11	거리로 이웃을 찾는데 콜레스테롤(200대)과 0/1 값이 섞여 큰 숫자가 거리를 좌우해서	수업 7 · 모델별 결과
12	0.5 무작위 추측, 0.7 실무 가능, 0.9 매우 우수, 1.0 데이터 누수 의심	수업 8 · AUC
13	양성 "예" 줄. 테스트의 실제 이탈 고객 수	수업 8 · classification_report

번호	정답	복습 위치
14	양성 = 이탈 고객 / 기준 모델 정확도 = 73.5% / 고비용 오류 = FN / 목표 = 재현율 최대화, 월 연락 한도 900명	수업 8 · 문제 정의서
15	임계값 조정, 가중치 조정(class_weight), 리샘플링. class_weight=balanced (874명 연락, 놓침 114명)	수업 8 · 클래스 불균형 대응
16	"다음 달 이탈 예상 고객 874명을 선정했습니다. 실제 이탈 561명 중 447명이 포함됩니다. 나머지 427명은 잔류 고객이라 쿠폰 비용이 추가됩니다."	수업 8 · 보고 문장
17	정답(레이블) 열이 있나 없나. 채점할 정답이 없으므로 쓸모로 사람이 판단	수업 9 · 지도 vs 비지도
18	① 중심점 k개 임의 배치 ② 가장 가까운 중심에 배정 ③ 중심을 그룹 평균으로 이동, 멈출 때까지 반복. k는 사람이, 운영에서 다르게 대응할 수 있는 그룹 수로	수업 9 · k-means
19	총결제액(최대 8,684)이 월요금(최대 118)보다 훨씬 커서 거리 계산을 거의 다 차지 → 그룹이 총결제액 구간으로만 잘림	수업 9 · 군집이 틀어지는 경우
20	해석(이름과 할 일)이 빠졌다. 분류는 '누구에게' 연락할지, 군집은 '무슨 말을' 할지	수업 9 · 세그먼트 해석
21	사람이 고를 수 있는 열로 정리돼 있으면 정형, 아니면 비정형. 224 × 224 × 3 = 150,528개	수업 10 · 정형 vs 비정형
22	머신러닝은 사람, 딥러닝은 모델 (앞층 선·모서리 → 뒷층 복잡한 모양)	수업 10 · 특성 추출의 주체
23	2 × 2 = 4, 오차 +3. 출력이 목표보다 크므로 a를 줄인다 (→ 1 → 0.5)	수업 10 · 가중치 갱신
24	층이 없으면 직선 하나만 긋을 수 있어서. 학습 데이터는 거의 다 맞히는데 새 데이터에서 약 7배 틀리는 과적합	수업 10 · TensorFlow Playground
25	이미 수많은 이미지로 학습된 층은 그대로 두고 마지막 층만 내 사진으로 새로 학습. 파인튜닝	수업 11 · 가중치 빌려 쓰기
26	학습 = 가중치를 처음부터 찾기 (GPU 여러 대로 며칠). 추론 = 학습된 가중치를 사진에 한 번 적용 (노트북 CPU로 충분)	수업 11 · GPU
27	무엇으로 학습했는지 (태그 줄). imagenet-1k / WhitePeak/shopping_review	수업 11 · Hugging Face
28	① 224 × 224로 크기 조정 ② (224, 224, 3) 배열 ③ 255로 나눠 정규화. 186 ÷ 255 ≈ 0.73	수업 11 · 이미지 전처리

번호	정답	복습 위치
29	3 × 3 같은 작은 창을 사진 위로 한 칸씩 옮기며 훑는 것. 창 안 숫자 = 가중치 (어떤 커널은 세로선에, 어떤 커널은 가로선에 반응)	수업 11 · CNN
30	1위 확률이 낮으므로 모델도 헷갈린다 → 사람이 다시 봐야 함. 틀린 답 아래 정답이 숨어 있을 수 있어서 (우산은 3위 3.7%)	수업 12 · Top-3
31	배경에 다른 물건, 낯선 촬영 각도, 클래스 목록에 없는 물건. 이어폰은 목록에 없음 → 내 카테고리로 파인튜닝	수업 12 · 오분류 원인
32	토큰화 → 토큰 ID → 임베딩 → 모델 입력	수업 13 · 텍스트가 숫자가 되는 길
33	길이: 원-핫은 사전 크기만큼 (119,547), 임베딩은 정해진 길이 (768). 의미: 원-핫은 없음, 임베딩은 뜻이 가까운 단어가 가까운 좌표 (좋아요-만족 0.99)	수업 13 · 원-핫 vs 임베딩
34	모델 B. 목표 지표인 재현율이 81.6% → 92.3%로 높고 놓친 부정 리뷰가 184 → 77건. 쇼핑 리뷰로 학습해 내 데이터와 가까움. 정밀도 차이(95.6 vs 94.0)는 작고 화난 손님을 놓치는 게 더 비싸므로	수업 13 · 모델 A vs B
35	분류 모델 B는 긍정 95%, ChatGPT는 부정(반어법). 분류 모델은 쇼핑 리뷰에 나온 표현만 배웠고, LLM은 웹 텍스트 수조 토큰으로 반어법·신조어도 봤으므로	수업 13 · 분류 모델 vs LLM
36	분류 모델 / LLM / LLM. 답이 정해진 일을 대량으로 = 분류 모델, 요약·답장 = LLM	수업 13 · 용도별 선택